Промежуточный отчёт: ускорение инференса Super-Resolution U-Net

Команда 52: Артём Чубов, Андрей Петухов, Евгений Веселков

1 апреля 2026

1 Введение

Цель проекта состоит в обучении и последующем ускорении инференса U-Net-подобной модели. В качестве задачи, которую должна решать наша модель, мы выбрали single-image super-resolution, мы сравниваем несколько вариантов инференса на одной и той же архитектуре и одном и том же наборе данных. В работе оцениваются как метрики качества восстановления изображения, так и вычислительные характеристики. Основное внимание уделяется метрикам PSNR (Peak signal to noise ratio) и SSIM (Structural similarity index measure) с точки зрения качества, а с точки зрения инференса - latency и пропускная способность.

2 Постановка задачи

В проекте рассматривается задача single-image super-resolution. В качестве базовой модели используется лёгкая U-Net-подобная encoder-decoder архитектура со skip-connection-ами. Эксперименты проводятся на датасете DIV2K, разделённом на обучающую, валидационную и тестовую выборки. К настоящему моменту мы успели поэкспериментировать с коэффициентами масштабирования $\times 4$ и $\times 8$. Вход в нейросеть формируется из изображения в высоком разрешении через bicubic downsampling, после чего он bicubic upsample-ится обратно до исходного размера и в таком виде подаётся в модель. Качество реконструкции оценивается с помощью PSNR и SSIM. Эксперименты организованы в виде единого репозитория проекта на GitHub.

3 Ход первого этапа

На первом этапе была подготовлена схема работы с данными, реализован и обучен бейзлайн, после чего проведена первичная оценка качества на валидации. Следующим шагом стали замеры производительности инференса на GPU в режимах FP32 и FP16. На данный момент сравнения FP32 и FP16 проведены для модели $\times 4$. Для масштаба $\times 8$ получены первые результаты по качеству на валидации.

4 Текущие результаты

Промежуточные результаты первого эксперимента для модели U-Net SR со scale factor ×4 приведены в таблице 1.

Таблица 1: Сравнение FP32 и FP16 инференса для U-Net SR ×4

Пайплайн	Latency, ms	P50, ms	P95, ms	Throughput, img/s	PSNR	SSIM
FP32	5.71	5.35	6.70	175.2	23.86	0.678
FP16	**5.15**	**5.02**	**6.23**	**194.2**	23.86	0.678

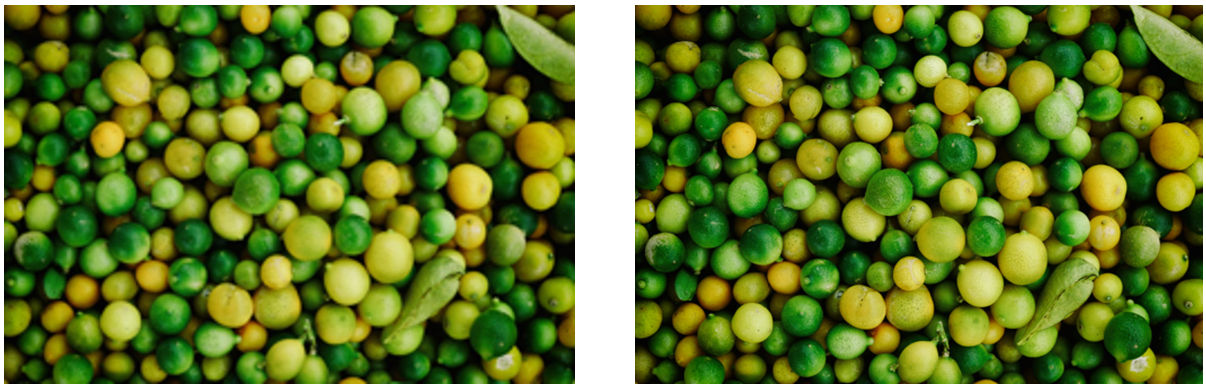

(a) Входное изображение в низком разрешении

(b) Предсказание модели, разрешение ×8

Рис. 1: Визуальный пример работы бейзлайн-модели

На рисунке 1 приведён пример работы модели для масштаба ×8. Слева показан входной кадр, а справа - предсказание модели.

5 Дальнейший план

Следующий этап проекта связан с расширением числа сравниваемых режимов инференса. После фиксации бейзлайна в FP16 планируется исследовать ускорение с использованием `torch.compile` и сравнить несколько режимов компиляции. Затем предполагается перейти к альтернативным компиляторным стекам, в частности TVM или близким решениям, чтобы проверить, можно ли получить дополнительный выигрыш за счёт autotuning и более агрессивной оптимизации вычислительного графа.

Отдельное направление связано с исследованием квантизации, прунинга и спарсности. Здесь интересно, конечно, насколько сильно такие преобразования повлияют не только на скорость, но и на итоговое качество.